



**Universidade de Brasília
Departamento de Estatística**

**Fatores Associados ao Tempo de Permanência de Funcionários:
uma aplicação de modelos de regressão paramétricos em análise
de sobrevivência**

**Ana Beatriz Silva Martinez
Julia Lima Nosralla
Lucas Fonseca Alves
Prof(a). Juliana Betini Fachini Gomes**

Relatório apresentado para a disciplina
Análise de Sobrevivência (2026.1) como
parte dos requisitos necessários para
aprovação.

**Brasília
2026**

Sumário

1 Introdução	6
2 Referencial teórico	8
2.1 Análise de sobrevivência	8
2.2 Censura	8
2.3 Funções utilizadas na análise de sobrevivência	9
2.3.1 Função de sobrevivência	9
2.3.2 Função de risco	10
2.3.3 Função de risco acumulado	10
2.4 Estimador de Kaplan-Meier	11
2.5 Comparação entre curvas de sobrevivência	11
2.5.1 Teste de Log-rank	12
2.5.2 Teste de Wilcoxon	12
2.6 Modelos probabilísticos	12
2.6.1 Distribuição exponencial	12
2.6.2 Distribuição Weibull	13
2.6.3 Distribuição log-normal	13
2.6.4 Distribuição log-logística	14
2.7 Estimação por máxima verossimilhança	14
2.8 Modelos de regressão paramétricos	15
2.9 Modelos de locação e escala	16
2.10 Seleção do modelo	18
2.11 Análise de resíduos	18
2.11.1 Resíduo de Cox-Snell	19
3 Metodologia	19
3.1 Base de dados	19
3.2 Análise descritiva	20
3.3 Relação entre as covariáveis	21
3.4 Ajuste das distribuições	22

3.5 Seleção de covariáveis	22
3.6 Análise de diagnóstico	23
4 Análise descritiva	24
4.1 Tempo de experiência	24
4.2 Mentoria.	26
4.3 Gênero.	27
4.4 Gênero do Supervisor	29
4.5 Indústria	30
4.6 Transporte	32
4.7 Salário Cinza	33
4.8 Profissão.	35
4.9 Canal de Recrutamento	36
4.10 Idade	38
4.11 Ansiedade	39
4.12 Extroversão	41
4.13 Independência	42
4.14 Inovação	44
4.15 Autocontrole.	45
4.16 Correlação	46
4.16.1 Correlação entre variáveis quantitativas	46
4.16.2 Correlação entre variáveis categóricas	47
5 Ajuste de distribuições	48
6 Seleção de covariáveis.	51
7 Análise de diagnóstico	52
7.1 Resíduo de Cox-Snell.	52
8 Interpretação do modelo selecionado	54
8.1 Idade.	56
8.2 Indústria	56
8.3 Profissão.	57
8.4 Canal de recrutamento.	57

8.5 Salário cinza	57
8.6 Transporte	58
8.7 Autocontrole e ansiedade	58
9 Conclusão	58
A Estimativas completas do modelo Weibull	60

1 Introdução

A permanência de funcionários em uma organização é um aspecto relevante para a gestão de pessoas, uma vez que a rotatividade pode gerar impactos relacionados à perda de conhecimento, aos custos de recrutamento e treinamento e à continuidade das atividades. Nesse contexto, compreender o tempo até a saída de um funcionário e identificar características associadas à sua permanência pode contribuir para o planejamento de políticas de retenção e para a tomada de decisões organizacionais.

A análise de sobrevivência reúne métodos estatísticos destinados ao estudo do tempo até a ocorrência de determinado evento de interesse. Diferentemente de técnicas estatísticas convencionais, essa abordagem permite incorporar observações censuradas, correspondentes aos indivíduos para os quais o evento não foi observado durante o período de acompanhamento. No presente estudo, o tempo de sobrevivência corresponde ao tempo de experiência do indivíduo na empresa, medido em meses. Já o evento de interesse é a saída do funcionário da organização. Os funcionários cuja saída não foi registrada ou que não foram acompanhados até o final do estudo são tratados como observações censuradas. A presença de uma proporção relevante de censuras na base de dados reforça a adequação do uso dessas técnicas.

Este trabalho tem como objetivo analisar o tempo de permanência dos funcionários e investigar a associação entre esse tempo e características pessoais, profissionais e organizacionais. Entre as variáveis consideradas estão idade, gênero, gênero do supervisor, existência de mentoria, setor de atuação, profissão, canal de recrutamento, meio de transporte, recebimento de salário não declarado e indicadores comportamentais, como ansiedade, extroversão, independência, inovação e autocontrole.

Inicialmente, foi realizada uma análise descritiva dos tempos de sobrevivência e das covariáveis. Para as variáveis categóricas, foram estimadas curvas de Kaplan-Meier, aplicados testes de comparação entre as curvas e calculados os coeficientes de correlação entre as variáveis. Para as variáveis quantitativas, foram utilizadas medidas-resumo, gráficos e análises de correlação. Em seguida, diferentes distribuições paramétricas foram ajustadas aos tempos observados e comparadas por meio de inspeção gráfica e do Critério de Informação de Akaike. Posteriormente, foram aplicados procedimentos de seleção de covariáveis e técnicas de diagnóstico baseadas nos resíduos de Cox-Snell com o objetivo de avaliar a adequação do modelo e identificar possíveis problemas de especificação.

Por fim, o modelo selecionado é interpretado a partir dos efeitos estimados para as covariáveis, buscando identificar os fatores associados ao aumento ou à redução do tempo de permanência dos funcionários. Dessa forma, pretende-se fornecer uma descrição estatística consistente do processo de saída da organização e compreender quais características

apresentam maior relevância para a retenção dos trabalhadores.

2 Referencial teórico

Nesta seção, serão apresentados os principais conceitos e métodos de análise de sobrevivência utilizados no desenvolvimento do trabalho. Serão abordados o tempo de falha, a censura, as funções de sobrevivência e risco, o estimador de Kaplan-Meier, os testes de comparação entre curvas, os modelos probabilísticos, os modelos de regressão paramétricos e os resíduos utilizados na análise de diagnóstico.

2.1 Análise de sobrevivência

A análise de sobrevivência é uma área da Estatística que reúne técnicas e métodos destinados ao estudo do tempo decorrido até a ocorrência de um evento de interesse (COLOSIMO; GIOLO, 2006).

Embora o termo sobrevivência esteja frequentemente associado ao tempo até a morte de um indivíduo, esses métodos podem ser aplicados em diferentes contextos. O evento analisado pode representar, por exemplo, a falha de um equipamento, a recuperação de um paciente, a inadimplência de um cliente ou a saída de um funcionário de uma empresa.

A variável resposta é denominada tempo de falha e corresponde ao tempo até a ocorrência do evento de interesse. Para sua definição, é necessário estabelecer o início do acompanhamento, a escala de medida do tempo e o evento que será considerado como falha.

2.2 Censura

Uma característica importante dos dados de sobrevivência é a presença de censura. A censura ocorre quando não é possível observar completamente o tempo até a ocorrência do evento de interesse. Apesar disso, a informação disponível até o último tempo observado ainda deve ser considerada na análise.

Neste trabalho, foram observadas censuras à direita aleatórias. Em alguns casos, o acompanhamento do funcionário foi interrompido antes da ocorrência do evento de interesse por motivos distintos do desligamento da empresa. Para esses indivíduos, o tempo registrado corresponde ao último momento em que permaneceram sob acompanhamento, sabendo-se apenas que o verdadeiro tempo até o desligamento é superior ao valor observado.

Sejam T_i o verdadeiro tempo até o desligamento e C_i o tempo de censura do

indivíduo i . O tempo observado pode ser representado por

$$t_i = \min(T_i, C_i),$$

acompanhado pelo indicador

$$\delta_i = \begin{cases} 1, & \text{se } T_i \leq C_i, \\ 0, & \text{se } T_i > C_i. \end{cases}$$

Assim, $\delta_i = 1$ indica que o desligamento foi observado, enquanto $\delta_i = 0$ indica uma observação censurada. Para a realização das análises, considerou-se a suposição de independência entre o tempo de censura e o tempo até a ocorrência do desligamento.

2.3 Funções utilizadas na análise de sobrevivência

Seja T uma variável aleatória não negativa que representa o tempo até a ocorrência do evento de interesse. A distribuição de T pode ser descrita por diferentes funções.

2.3.1 Função de sobrevivência

A função de sobrevivência representa a probabilidade de um indivíduo não apresentar o evento de interesse até o tempo t . Essa função é definida por

$$S(t) = P(T > t).$$

No contexto deste trabalho, $S(t)$ representa a probabilidade de um funcionário permanecer na empresa por um período superior a t meses.

A função de sobrevivência assume valores entre zero e um e é uma função não crescente. Dessa forma, quanto maior o tempo considerado, menor ou igual será a probabilidade de permanência do funcionário na empresa.

A função de distribuição acumulada é dada por

$$F(t) = P(T \leq t) = 1 - S(t),$$

e representa a probabilidade de o evento ocorrer até o tempo t .

2.3.2 Função de risco

A função de risco representa a taxa instantânea de ocorrência do evento no tempo t , dado que o indivíduo permaneceu sem apresentar o evento até esse momento. Essa função é definida por

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t}.$$

No presente estudo, $h(t)$ representa a taxa instantânea de saída de um funcionário no tempo t , considerando que ele permaneceu na empresa até esse período.

A função de risco também pode ser escrita como

$$h(t) = \frac{f(t)}{S(t)},$$

em que $f(t)$ representa a função densidade de probabilidade do tempo de sobrevivência.

2.3.3 Função de risco acumulado

A função de risco acumulado representa o risco acumulado de ocorrência do evento até o tempo t e é definida por

$$H(t) = \int_0^t h(u) du.$$

Essa função possui a seguinte relação com a função de sobrevivência:

$$H(t) = -\log[S(t)].$$

Consequentemente,

$$S(t) = \exp[-H(t)].$$

A função de risco acumulado é não decrescente. Assim, quanto maior o tempo de acompanhamento, maior ou igual será o risco acumulado de ocorrência do evento.

2.4 Estimador de Kaplan-Meier

O estimador de Kaplan-Meier é um método não paramétrico utilizado para estimar a função de sobrevivência na presença de observações censuradas. Por ser um método não paramétrico, não é necessário definir previamente uma distribuição de probabilidade para o tempo de sobrevivência (COLOSIMO; GIOLO, 2006).

O estimador de Kaplan-Meier é definido por

$$\hat{S}(t) = \prod_{j:t_j \leq t} \left(1 - \frac{d_j}{n_j}\right),$$

em que t_j representa o j -ésimo tempo distinto de falha, d_j é o número de falhas observadas no tempo t_j e n_j é o número de indivíduos sob risco imediatamente antes desse tempo.

A curva estimada apresenta formato de escada. As quedas ocorrem nos tempos em que são observadas falhas. Por outro lado, as censuras não provocam quedas na curva, mas fazem com que o indivíduo deixe de fazer parte do conjunto sob risco nos tempos seguintes.

O estimador de Kaplan-Meier permite analisar o comportamento geral dos tempos de sobrevivência e comparar a permanência entre diferentes grupos.

A partir da estimativa da função de sobrevivência, a função de risco acumulado pode ser estimada por

$$\hat{H}(t) = -\log[\hat{S}(t)].$$

2.5 Comparação entre curvas de sobrevivência

Quando existem covariáveis categóricas, pode-se ter interesse em comparar as curvas de sobrevivência dos diferentes grupos.

As hipóteses avaliadas nos testes de comparação são

$$\begin{cases} H_0 : \text{não há diferença entre as curvas de sobrevivência;} \\ H_1 : \text{há diferença entre as curvas de sobrevivência.} \end{cases}$$

2.5.1 Teste de Log-rank

O teste de Log-rank compara, em cada tempo de falha, o número de eventos observados em cada grupo com o número esperado sob a hipótese de igualdade entre as curvas.

Esse teste é particularmente apropriado quando a razão entre as funções de risco dos grupos é aproximadamente constante ao longo do tempo, situação conhecida como suposição de riscos proporcionais.

A presença de vários cruzamentos entre as curvas de sobrevivência pode representar um indício de que essa suposição não é atendida. Entretanto, a avaliação gráfica deve ser considerada apenas como uma verificação inicial.

2.5.2 Teste de Wilcoxon

O teste de Wilcoxon generalizado também é utilizado para comparar curvas de sobrevivência. Entretanto, esse teste atribui maior peso aos tempos iniciais, nos quais geralmente existe um número maior de indivíduos sob risco.

Dessa forma, o teste de Wilcoxon pode ser utilizado quando as diferenças entre os grupos ocorrem principalmente no início do acompanhamento ou quando são observados cruzamentos entre as curvas.

2.6 Modelos probabilísticos

O tempo de sobrevivência é uma variável aleatória contínua e não negativa. Além disso, frequentemente apresenta uma distribuição assimétrica. Por esse motivo, a distribuição normal não é utilizada diretamente para modelar o tempo T .

Entre as distribuições probabilísticas utilizadas para modelar tempos de sobrevivência estão a exponencial, Weibull, log-normal e log-logística (LAWLESS, 2003).

2.6.1 Distribuição exponencial

Se o tempo T apresenta distribuição exponencial com parâmetro de escala $\alpha > 0$, sua função de sobrevivência é dada por

$$S(t) = \exp\left(-\frac{t}{\alpha}\right), \quad t \geq 0.$$

A função de risco é dada por

$$h(t) = \frac{1}{\alpha}.$$

Portanto, a distribuição exponencial apresenta risco constante ao longo do tempo. Essa característica significa que a taxa instantânea de ocorrência do evento não depende do tempo já permanecido em acompanhamento.

2.6.2 Distribuição Weibull

A distribuição Weibull é uma generalização da distribuição exponencial e permite que a função de risco aumente ou diminua ao longo do tempo.

Considerando $\alpha > 0$ como parâmetro de escala e $\gamma > 0$ como parâmetro de forma, a função de sobrevivência é dada por

$$S(t) = \exp \left[- \left(\frac{t}{\alpha} \right)^\gamma \right].$$

A função de risco é expressa por

$$h(t) = \frac{\gamma}{\alpha} \left(\frac{t}{\alpha} \right)^{\gamma-1}.$$

O comportamento da função de risco depende do parâmetro γ . Quando $\gamma = 1$, o risco é constante e a distribuição Weibull se reduz à distribuição exponencial. Quando $\gamma > 1$, o risco é crescente e, quando $\gamma < 1$, o risco é decrescente.

2.6.3 Distribuição log-normal

A distribuição log-normal é obtida quando o logaritmo do tempo de sobrevivência apresenta distribuição normal. Nesse caso,

$$Y = \log(T)$$

possui distribuição normal com parâmetro de locação μ e parâmetro de escala $\sigma > 0$.

A função de sobrevivência é dada por

$$S(t) = 1 - \Phi\left(\frac{\log(t) - \mu}{\sigma}\right),$$

em que $\Phi(\cdot)$ representa a função de distribuição acumulada da normal padrão.

Essa distribuição permite representar situações em que a função de risco inicialmente aumenta e, após determinado período, começa a diminuir.

2.6.4 Distribuição log-logística

A distribuição log-logística é obtida quando o logaritmo do tempo apresenta distribuição logística. Sua função de sobrevivência pode ser escrita como

$$S(t) = \frac{1}{1 + \left(\frac{t}{\alpha}\right)^\gamma},$$

em que $\alpha > 0$ representa o parâmetro de escala e $\gamma > 0$ representa o parâmetro de forma.

Dependendo do valor do parâmetro de forma, a função de risco pode ser decrescente ou apresentar crescimento seguido de redução.

2.7 Estimação por máxima verossimilhança

Para que um modelo probabilístico fique determinado, é necessário estimar seus parâmetros. Na presença de censura, o método de mínimos quadrados não é apropriado, pois não incorpora adequadamente as informações das observações censuradas.

Por esse motivo, os parâmetros dos modelos de sobrevivência são geralmente estimados pelo método de máxima verossimilhança. Esse método procura os valores dos parâmetros que tornam a amostra observada mais provável.

Para uma observação de falha, a contribuição para a função de verossimilhança é dada pela função densidade $f(t_i; \boldsymbol{\theta})$. Para uma observação censurada, a contribuição é dada pela função de sobrevivência $S(t_i; \boldsymbol{\theta})$.

Assim, a função de verossimilhança na presença de censura à direita pode ser escrita como

$$L(\boldsymbol{\theta}) = \prod_{i=1}^n [f(t_i; \boldsymbol{\theta})]^{\delta_i} [S(t_i; \boldsymbol{\theta})]^{1-\delta_i},$$

em que $\boldsymbol{\theta}$ representa o vetor de parâmetros do modelo.

Os estimadores de máxima verossimilhança correspondem aos valores de θ que maximizam essa função.

2.8 Modelos de regressão paramétricos

Na prática, os indivíduos podem apresentar características diferentes que afetam seus tempos de sobrevivência. Essas características são representadas por covariáveis, como idade, gênero, profissão e outras variáveis de interesse.

Os modelos de regressão paramétricos permitem estudar a relação entre o tempo de sobrevivência e essas covariáveis. Para isso, os parâmetros da distribuição são relacionados ao vetor de variáveis explicativas.

Uma forma comum de representar essa relação é por meio dos modelos de locação e escala. Nesses modelos, considera-se

$$Y = \log(T)$$

e escreve-se

$$Y_i = \mathbf{x}_i^T \boldsymbol{\beta} + \sigma W_i,$$

em que $\mathbf{x}_i$ representa o vetor de covariáveis, $\boldsymbol{\beta}$ é o vetor de parâmetros associados às covariáveis, $\sigma > 0$ é o parâmetro de escala e W_i representa o erro aleatório com distribuição conhecida.

Nesse modelo, as covariáveis atuam de forma linear sobre o logaritmo do tempo e de forma multiplicativa sobre o tempo original.

A quantidade

$$\exp(\beta_j)$$

é denominada razão de tempos ou fator de aceleração. Para uma covariável quantitativa, esse valor representa o fator pelo qual o tempo de sobrevivência é multiplicado quando ocorre um aumento de uma unidade na covariável, mantendo as demais constantes.

Quando

$$\exp(\beta_j) > 1,$$

o aumento da covariável está associado ao aumento do tempo de sobrevivência. Quando

$$\exp(\beta_j) < 1,$$

o aumento da covariável está associado à redução do tempo de sobrevivência.

Para covariáveis categóricas, a interpretação é feita por meio da comparação de cada categoria com a categoria de referência.

As distribuições exponencial, Weibull, log-normal e log-logística podem ser representadas na forma de modelos de locação e escala. No logaritmo do tempo, elas estão associadas, respectivamente, às distribuições valor extremo padrão, valor extremo, normal e logística.

2.9 Modelos de locação e escala

Outra forma de representar os modelos paramétricos de sobrevivência é por meio dos modelos de locação e escala, também conhecidos como modelos de tempo de vida acelerado.

Seja T uma variável aleatória que representa o tempo até a ocorrência do evento de interesse e considere a transformação

$$Y = \log(T).$$

A classe de modelos de locação e escala se caracteriza pelo fato de que Y apresenta uma distribuição com parâmetro de locação dependente das covariáveis e parâmetro de escala $\sigma > 0$. O modelo pode ser escrito como

$$Y_i = \mu(\mathbf{x}_i) + \sigma W_i,$$

em que $\mu(\mathbf{x}_i)$ representa o parâmetro de locação para o indivíduo i , σ é o parâmetro de escala e W_i é um erro aleatório com distribuição conhecida e independente das covariáveis.

Em geral, considera-se

$$\mu(\mathbf{x}_i) = \mathbf{x}_i^T \boldsymbol{\beta},$$

em que $\mathbf{x}_i$ é o vetor de covariáveis do indivíduo e $\boldsymbol{\beta}$ é o vetor de parâmetros

associados a essas covariáveis. Dessa forma, o modelo pode ser representado por

$$\log(T_i) = \mathbf{x}_i^T \boldsymbol{\beta} + \sigma W_i.$$

Nesse tipo de modelo, as covariáveis atuam de forma linear sobre o logaritmo do tempo. Entretanto, ao retornar para a escala original, essa relação passa a ser multiplicativa, pois

$$T_i = \exp(\mathbf{x}_i^T \boldsymbol{\beta}) \exp(\sigma W_i).$$

Assim, a quantidade $\exp(\beta_j)$ pode ser interpretada como o fator pelo qual o tempo de sobrevivência é multiplicado quando ocorre um aumento de uma unidade na covariável X_j , mantendo as demais covariáveis constantes.

A interpretação de $\exp(\beta_j)$ pode ser resumida por

$$\begin{cases} \exp(\beta_j) > 1, & \text{o aumento da covariável está associado ao aumento do tempo até o evento;} \\ \exp(\beta_j) = 1, & \text{não há alteração no tempo associada à covariável;} \\ \exp(\beta_j) < 1, & \text{o aumento da covariável está associado à redução do tempo até o evento.} \end{cases}$$

Para as covariáveis categóricas, a interpretação é realizada por meio da comparação de cada categoria com a categoria utilizada como referência.

As distribuições consideradas anteriormente podem ser representadas na forma de modelos de locação e escala por meio da transformação do tempo. As relações utilizadas são:

Distribuição de T	Distribuição de $Y = \log(T)$
Exponencial	Valor extremo padrão
Weibull	Valor extremo
Log-normal	Normal
Log-logística	Logística

No caso da distribuição exponencial, a distribuição valor extremo padrão possui parâmetro de escala fixado. Já no modelo Weibull, o parâmetro de escala é estimado.

Portanto, as formas valor extremo padrão, valor extremo, normal e logística não representam um grupo de distribuições sem relação com os modelos anteriores. Elas correspondem às representações no logaritmo do tempo das distribuições exponencial, Weibull, log-normal e log-logística, respectivamente.

Neste trabalho, essas representações foram ajustadas como uma análise complementar. Seus resultados foram avaliados por meio da comparação gráfica com a curva de Kaplan-Meier, do Critério de Informação de Akaike e da análise de resíduos.

2.10 Seleção do modelo

A escolha da distribuição probabilística é uma etapa importante na análise paramétrica dos tempos de sobrevivência. Para isso, podem ser utilizadas técnicas gráficas e medidas de comparação entre modelos.

Uma das técnicas gráficas consiste em comparar a função de sobrevivência estimada pelo modelo probabilístico com a curva obtida pelo método de Kaplan-Meier. O modelo mais adequado será aquele cuja curva acompanhar melhor a curva empírica ao longo do período observado.

Além da comparação gráfica, pode ser utilizado o Critério de Informação de Akaike, definido por

$$AIC = -2 \log L(\hat{\theta}) + 2p,$$

em que $L(\hat{\theta})$ representa a função de verossimilhança avaliada nos parâmetros estimados e p corresponde ao número de parâmetros do modelo.

O AIC considera simultaneamente a qualidade do ajuste e a complexidade do modelo. Entre os modelos comparáveis, aquele que apresenta o menor valor de AIC é considerado o mais adequado segundo esse critério.

Entretanto, a escolha do modelo não deve ser realizada apenas com base no AIC. Também devem ser avaliadas a proximidade das curvas estimadas, a interpretação dos parâmetros e a análise de diagnóstico.

2.11 Análise de resíduos

A análise de resíduos tem como objetivo avaliar a adequação da distribuição proposta, verificar as suposições do modelo, identificar pontos extremos e analisar a forma funcional das covariáveis.

As técnicas de resíduos devem ser utilizadas para identificar modelos claramente inadequados, e não para provar que determinado modelo está correto. Em algumas situações, mais de um modelo pode apresentar ajuste razoável aos dados (KLEIN; MOESCHBERGER, 2003).

Entre os resíduos mais utilizados em análise de sobrevivência estão os resíduos de Cox-Snell, Martingale e Deviance.

2.11.1 Resíduo de Cox-Snell

O resíduo de Cox-Snell é utilizado para avaliar o ajuste global do modelo. Para o indivíduo i , é definido por

$$\hat{e}_i = \hat{H}(t_i | \mathbf{x}_i),$$

em que $\hat{H}(t_i | \mathbf{x}_i)$ representa a função de risco acumulado estimada pelo modelo no tempo observado.

Utilizando a relação entre as funções de sobrevivência e risco acumulado, também pode ser escrito como

$$\hat{e}_i = -\log \left[\hat{S}(t_i | \mathbf{x}_i) \right].$$

Quando o modelo está adequadamente especificado, espera-se que os resíduos de Cox-Snell apresentem aproximadamente uma distribuição exponencial com parâmetro igual a um.

Para verificar essa condição, a curva de sobrevivência dos resíduos pode ser estimada pelo método de Kaplan-Meier e comparada à curva de sobrevivência da distribuição exponencial padrão. Quanto maior a proximidade entre as curvas, melhor é considerado o ajuste global do modelo.

3 Metodologia

Nesta seção, serão apresentados os procedimentos utilizados para a realização do estudo. As análises foram desenvolvidas no software R e foram divididas nas seguintes etapas: preparação da base de dados, análise descritiva, avaliação da relação entre as covariáveis, ajuste das distribuições, seleção de covariáveis e análise de diagnóstico dos modelos.

3.1 Base de dados

Os dados utilizados neste trabalho foram obtidos na plataforma Kaggle e apresentam informações relacionadas à rotatividade de funcionários. A base possui 1129

observações, que contém características pessoais, profissionais, organizacionais e comportamentais dos indivíduos.

Inicialmente, foi realizada uma preparação da base de dados. Para isso, foram verificadas possíveis inconsistências na escrita das categorias e as variáveis foram transformadas para os formatos adequados.

As variáveis gênero, indústria, profissão, canal de recrutamento, mentoria, gênero do supervisor, salário cinza e transporte foram consideradas categóricas. Por outro lado, idade, tempo de experiência, ansiedade, extroversão, independência, inovação e autocontrole foram tratadas como variáveis quantitativas.

Para o ajuste dos modelos, foram utilizadas apenas as observações que apresentavam informações completas para todas as variáveis analisadas. Dessa forma, todos os modelos foram ajustados considerando o mesmo conjunto de indivíduos, permitindo uma comparação mais adequada entre os resultados.

A variável resposta do estudo foi o tempo de experiência do funcionário na empresa, medido em meses. O evento de interesse foi definido como a saída do funcionário da organização.

Para cada indivíduo i , foram observados o tempo de experiência T_i e o indicador do evento δ_i , representados por

$$(T_i, \delta_i),$$

em que T_i indica o tempo observado de permanência do funcionário na empresa. Considerou-se $\delta_i = 1$ quando a saída do funcionário foi observada e $\delta_i = 0$ quando a observação foi censurada.

Neste estudo, a censura ocorreu à direita, isto é, o funcionário permaneceu na empresa até o final do período observado, sem que sua saída fosse registrada. Aproximadamente 49,42% das observações foram censuradas, o que reforça a necessidade da utilização de métodos de análise de sobrevivência.

3.2 Análise descritiva

Primeiramente, foi realizada uma análise descritiva da variável resposta com o objetivo de compreender o comportamento geral do tempo de experiência dos funcionários.

Para isso, a função de sobrevivência foi estimada pelo método de Kaplan-Meier. Foram construídos dois gráficos da curva de sobrevivência: um sem a indicação das censuras e outro com as marcas correspondentes às observações censuradas.

Também foi construído um gráfico da função de risco acumulado, a fim de observar como o risco acumulado de saída dos funcionários se comportava ao longo do tempo.

O gráfico do Tempo Total em Teste, conhecido como gráfico TTT, foi inicialmente considerado para avaliar o formato da função de risco. Entretanto, devido à elevada quantidade de observações censuradas, optou-se por não utilizar esse gráfico como principal critério para a escolha das distribuições.

Em seguida, foi realizada uma análise descritiva de cada covariável em relação à variável resposta. Para as variáveis categóricas, foram construídas curvas de sobrevivência de Kaplan-Meier para cada categoria. A igualdade entre as curvas foi avaliada por meio dos testes de Log-rank e Wilcoxon.

O teste de Log-rank foi utilizado quando as curvas apresentaram poucos cruzamentos e um comportamento aproximadamente proporcional. Nos casos em que foram observados vários cruzamentos entre as curvas, foi utilizado o teste de Wilcoxon, que atribui maior peso às falhas ocorridas nos tempos iniciais.

As hipóteses avaliadas foram

$$\begin{cases} H_0 : \text{não há diferença entre as curvas de sobrevivência;} \\ H_1 : \text{há diferença entre as curvas de sobrevivência.} \end{cases}$$

Para todos os testes, foi considerado o nível de significância de 5%.

Para as variáveis quantitativas, foram construídos gráficos boxplot segundo a ocorrência do evento, separando as observações censuradas das observações de falha. Também foram calculadas medidas resumo, como média, desvio-padrão, mínimo, primeiro quartil, mediana, terceiro quartil e máximo.

3.3 Relação entre as covariáveis

Nesta etapa, foi avaliada a relação entre as covariáveis com o objetivo de identificar possíveis problemas de multicolinearidade.

Para as variáveis quantitativas, foi calculado o coeficiente de correlação de Spearman. Os resultados foram apresentados por meio de um mapa de calor, facilitando a visualização da direção e da intensidade das correlações.

Para as variáveis categóricas, foi utilizada a medida V de Cramér. Essa medida foi calculada para todos os pares de variáveis categóricas e os resultados também foram apresentados em um mapa de calor.

Após a seleção do modelo final, também foi calculado o Fator de Inflação da

Variância para avaliar a presença de multicolinearidade entre as covariáveis selecionadas.

3.4 Ajuste das distribuições

Nesta etapa, foram ajustadas diferentes distribuições paramétricas aos tempos de sobrevivência, com o objetivo de identificar aquelas que apresentavam maior proximidade com os dados observados.

Inicialmente, foram consideradas as distribuições exponencial, Weibull, log-normal e log-logística. Para cada distribuição, foi ajustado um modelo contendo apenas o intercepto.

Em seguida, as curvas de sobrevivência estimadas pelos modelos foram comparadas graficamente à curva de Kaplan-Meier. Essa comparação permitiu avaliar quais distribuições reproduziam melhor o comportamento dos tempos de permanência.

Além da análise gráfica, foi utilizado o Critério de Informação de Akaike, dado por

$$AIC = -2\ell(\hat{\theta}) + 2k,$$

em que $\ell(\hat{\theta})$ representa o valor da log-verossimilhança do modelo e k corresponde ao número de parâmetros estimados. Menores valores de AIC indicam um melhor equilíbrio entre a qualidade do ajuste e a quantidade de parâmetros do modelo.

Também foram avaliados modelos na forma de locação-escala. Para isso, foi utilizado o logaritmo do tempo como variável resposta e foram consideradas as distribuições valor extremo padrão, valor extremo, normal e logística.

Como os valores de AIC foram próximos entre algumas distribuições, a escolha do modelo final não foi realizada apenas com base nessa medida. Também foram considerados os resultados da análise gráfica e da análise de diagnóstico.

3.5 Seleção de covariáveis

Após o ajuste das distribuições, foram construídos modelos de regressão considerando as covariáveis disponíveis na base. Para cada distribuição, foi inicialmente ajustado um modelo completo contendo idade, gênero, indústria, profissão, canal de recrutamento, mentoria, gênero do supervisor, salário cinza, transporte, extroversão, independência, autocontrole, ansiedade e inovação.

Em seguida, foram aplicados três procedimentos de seleção de covariáveis: passo

atrás, passo à frente e passo a passo. No procedimento passo atrás, iniciou-se com o modelo completo e as covariáveis foram retiradas gradualmente. No procedimento passo à frente, iniciou-se com o modelo contendo apenas o intercepto e as covariáveis foram adicionadas ao longo do processo. Já no procedimento passo a passo, foram permitidas tanto a inclusão quanto a retirada de covariáveis.

Para todos os procedimentos, foi utilizado o AIC como critério de seleção. De modo geral, os três métodos resultaram no mesmo conjunto de covariáveis para cada distribuição. No modelo Weibull, foram selecionadas as covariáveis idade, indústria, profissão, canal de recrutamento, salário cinza, transporte, autocontrole e ansiedade.

Entre os modelos ajustados diretamente ao tempo, o modelo Weibull apresentou o menor valor de AIC. Além disso, esse modelo apresentou o melhor resultado na análise dos resíduos de Cox-Snell. Dessa forma, ele foi selecionado como o modelo final do estudo.

3.6 Análise de diagnóstico

Por fim, foi realizada uma análise de diagnóstico com o objetivo de avaliar a qualidade do ajuste dos modelos selecionados.

Inicialmente, foram calculados os resíduos de Cox-Snell. Quando o modelo está corretamente especificado, espera-se que esses resíduos apresentem aproximadamente uma distribuição exponencial com parâmetro igual a um.

Para avaliar esse comportamento, a curva de sobrevivência dos resíduos foi estimada pelo método de Kaplan-Meier e comparada à curva de sobrevivência de uma distribuição exponencial padrão. Quanto maior a proximidade entre as curvas, melhor o ajuste do modelo. A partir dessa comparação, observou-se que o modelo Weibull apresentou a maior proximidade com a curva teórica, indicando melhor adequação aos dados em relação aos demais modelos.

4 Análise descritiva

Nesta seção, será realizada uma análise descritiva de cada variável a fim de compreender o comportamento geral dos dados.

4.1 Tempo de experiência

Esta seção tem como objetivo analisar o comportamento da variável tempo de experiência, que indica o tempo em meses do funcionário na empresa. Para isso, foram construídos dois gráficos da curva de sobrevivência de Kaplan-Meier e um gráfico da curva de risco acumulado, apresentados a seguir:




Figura 1: Curva de sobrevivência da variável tempo de experiência sem censura

Com base na Figura 1, observa-se que a curva apresenta um declínio contínuo e relativamente acentuado, especialmente nos primeiros 100 meses. Após esse marco, a curva se torna ligeiramente mais plana, com alguns degraus mais longos. Isso sugere que os funcionários que conseguem superar a marca de 8 anos na empresa tendem a ter uma taxa de saída menor. Ao final do período observado, a probabilidade de sobrevivência estabiliza perto de 0.02 (2%), indicando que pouquíssimos funcionários atingem esse tempo na empresa.




Figura 2: Curva de sobrevivência da variável tempo de experiência com censura

Na Figura 2, as pequenas marcas verticais presentes sobre a curva representam observações censuradas. Nota-se que as censuras estão distribuídas ao longo de praticamente todo o período de acompanhamento, embora sejam mais frequentes nos meses iniciais. Com o passar do tempo, são observadas menos censuras.




Figura 3: Curva de risco acumulado da variável tempo de experiência

A Figura 3 mostra que a curva de risco acumulado tem um comportamento praticamente linear nos primeiros 100 meses, indicando que, nesse período, a taxa de falha foi aproximadamente constante. Entre os meses 100 e 130, a inclinação da curva diminui levemente, mas apresenta uma subida acentuada logo depois. Por fim, nota-se que a curva apresenta um salto extenso por volta do mês 165 e, em seguida, fica estável até o final do período observado.

4.2 Mentoria

Esta seção procura investigar o comportamento da variável Mentoria, que expressa a presença ou ausência de um tutor, mentor ou orientador durante o período probatório do funcionário.

A variável apresenta três categorias: "não", quando o funcionário não teve nenhum acompanhamento durante o período probatório, "chefe direto", que indica que o mentor do funcionário foi o seu próprio chefe, e "sim", quando o funcionário teve um mentor que não era seu chefe direto. O gráfico da curva de sobrevivência pelas categorias da variável é apresentado a seguir:




Figura 4: Curva de sobrevivência da variável Mentoria

A Figura 4 evidencia que, nos primeiros 85 meses de acompanhamento, os fun-

cionários cujo orientador era o próprio chefe apresentam maiores probabilidades de sobrevivência. Entretanto, após esse período, observa-se cruzamentos entre as curvas das diferentes categorias, o que pode indicar uma possível violação da suposição de riscos proporcionais.

Os grupos sem mentor e com mentor apresentam comportamentos muito semelhantes no intervalo de 0 a 25 meses. A partir desse marco, a curva dos funcionários com orientador exibe um declínio mais acentuado do que a dos colaboradores sem acompanhamento. Esta última, por sua vez, mantém um decréscimo constante e estável ao longo de todo o tempo observado, destacando-se como a única trajetória em que existem censuras até os tempos finais de acompanhamento.

A partir do mês 125, nota-se um período em que a curva permanece constante nos grupos com acompanhamento de mentor e com acompanhamento do chefe e, por fim, a estimativa da função de sobrevivência atinge zero entre os meses 150 e 175.

A fim de testar a igualdade das curvas e dado que os riscos não são proporcionais, foi realizado o Teste de Wilcoxon, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Não há diferença entre as curvas.} \\ H_1 : \text{Há diferença entre as curvas.} \end{cases}$$

A tabela a seguir exibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 1: Resultado do Teste de Wilcoxon para verificação da igualdade entre as curvas

Variável	p-valor	Decisão
Mentoria	0,09	Não rejeita a hipótese nula

O resultado apresentado na Tabela 1 indica que, ao nível de significância de 5%, não há evidências estatísticas suficientes para rejeitar a hipótese nula de igualdade entre as curvas de sobrevivência.

4.3 Gênero

Esta seção tem como objetivo estudar o comportamento da variável Gênero, que representa o gênero do funcionário. Para isso, foi construído um gráfico com as curvas de sobrevivência de cada grupo, exposto a seguir:




Figura 5: Curva de sobrevivência da variável Gênero

Ao analisar a Figura 5, é possível verificar que as curvas de sobrevivência permanecem muito próximas nos primeiros 15 meses. Depois desse momento inicial, o grupo feminino apresenta uma queda mais acentuada na probabilidade de sobrevivência até o tempo aproximadamente 60, a partir do qual as curvas voltam a se aproximar.

Para a curva que representa o gênero masculino, nota-se que ocorre um salto grande entre os meses 125 e 150 e, por fim, a estimativa de sobrevivência para o grupo masculino atinge zero. Por outro lado, a trajetória feminina apresenta uma descida constante e, ao final do período observado, restam ainda algumas observações censuradas.

Dado que foram verificados poucos cruzamentos, considera-se que a suposição de proporcionalidade dos riscos foi atendida. Assim, com o objetivo de testar a igualdade entre as curvas, foi realizado o Teste de Logrank, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Não há diferença entre as curvas.} \\ H_1 : \text{Há diferença entre as curvas.} \end{cases}$$

A tabela a seguir exibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 2: Resultado do Teste de LogRank para verificação da igualdade entre as curvas

Variável	p-valor	Decisão
Gênero	0,1	Não rejeita a hipótese nula

O resultado apresentado na Tabela 2 indica que, ao nível de significância de 5%, não há evidências estatísticas suficientes para rejeitar a hipótese nula de igualdade entre as curvas de sobrevivência.

4.4 Gênero do Supervisor

Esta seção busca analisar o comportamento da variável Gênero do Supervisor, que indica o gênero do chefe do funcionário. Para isso, foi construído um gráfico das curvas de sobrevivência dos grupos, exibido a seguir:




Figura 6: Curva de sobrevivência da variável Gênero do Supervisor

Na Figura 6, observa-se que as curvas de sobrevivência são semelhantes nos primeiros 25 meses. Após esse marco, o grupo masculino apresenta uma queda mais rápida na probabilidade de sobrevivência até o tempo aproximadamente 75, a partir do qual as curvas se aproximam novamente.

Durante o período entre 125 e 150 meses, verifica-se um cruzamento entre as trajetórias, no qual o grupo masculino passa por um momento de estabilidade na probabilidade de sobrevivência enquanto ocorre uma descida mais acentuada para o grupo feminino. Nos tempos finais de acompanhamento, a estimativa da função de sobrevivência para o grupo de funcionários com supervisores do gênero masculino atinge zero, enquanto a curva correspondente ao grupo feminino permanece acima desse valor e apresenta as últimas observações censuradas do estudo.

Dado que foram verificados poucos cruzamentos, considera-se que a suposição de proporcionalidade dos riscos foi atendida. Assim, com o objetivo de testar a igualdade entre as curvas, foi realizado o Teste de Logrank, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Não há diferença entre as curvas.} \\ H_1 : \text{Há diferença entre as curvas.} \end{cases}$$

A tabela a seguir exibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 3: Resultado do Teste de LogRank para verificação da igualdade entre as curvas

Variável	p-valor	Decisão
Gênero do Supervisor	0,3	Não rejeita a hipótese nula

O resultado apresentado na Tabela 3 indica que, ao nível de significância de 5%, não há evidências estatísticas suficientes para rejeitar a hipótese nula de igualdade entre as curvas de sobrevivência.

4.5 Indústria

Esta seção procura examinar o comportamento da variável Indústria, que representa o setor de atuação da empresa do funcionário.

A variável apresenta 16 categorias: agricultura, bancos, construção, consultoria, HoReCa (hotéis, restaurantes e cafés), TI (tecnologia da informação), manufatura, mineração, farmácia, energia, imobiliárias, varejo, estatais, telecomunicação, transporte e outras. O gráfico da curva de sobrevivência pelas categorias da variável é apresentado a seguir:




Figura 7: Curva de sobrevivência da variável Indústria

A partir da Figura 7, verifica-se elevada heterogeneidade entre as curvas, indicando que o tempo de permanência dos funcionários varia entre os diferentes setores econômicos.

Os setores de Telecomunicações, Imobiliárias e Tecnologia da Informação apresentam, em geral, probabilidades de sobrevivência mais elevadas ao longo do período analisado, o que sugere uma maior retenção de funcionários. Por outro lado, setores como Agricultura, Construção, Consultoria e Bancos exibem declínio mais acentuado da função de sobrevivência.

Além disso, é possível notar a ocorrência de diversos cruzamentos entre as curvas, sugerindo violação da suposição de proporcionalidade dos riscos.

A fim de testar a igualdade das curvas e dado que os riscos não são proporcionais, foi realizado o Teste de Wilcoxon, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Não há diferença entre as curvas.} \\ H_1 : \text{Há diferença entre as curvas.} \end{cases}$$

A tabela a seguir exhibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 4: Resultado do Teste de Wilcoxon para verificação da igualdade entre as curvas

Variável	p-valor	Decisão
Indústria	< 0,001	Rejeita a hipótese nula

O resultado apresentado na Tabela 4 indica que, ao nível de significância de 5%, existem evidências estatísticas suficientes para rejeitar a hipótese nula de igualdade entre as curvas de sobrevivência.

4.6 Transporte

Esta seção tem como objetivo analisar o comportamento da variável Transporte, que representa o meio de transporte principal utilizado pelo funcionário. A variável possui três categorias: ônibus, carro ou a pé. O gráfico da curva de sobrevivência pelas categorias da variável é apresentado a seguir:




Figura 8: Curva de sobrevivência da variável Transporte

Ao analisar a Figura 8, observa-se que as curvas de sobrevivência dos três grupos permanecem bastante próximas durante os primeiros 15 meses de acompanhamento, embora a categoria Ônibus apresente uma redução ligeiramente mais acentuada na pro-

babilidade de sobrevivência. Após esse período, as curvas dos grupos Ônibus e Carro tornam-se bastante semelhantes, enquanto a curva correspondente aos funcionários que se deslocam a pé permanece acima das demais durante praticamente todo o período de observação, indicando maior probabilidade de permanência no emprego.

A partir de aproximadamente 25 meses, as curvas das categorias Carro e Ônibus passam a divergir. Os funcionários que utilizam ônibus apresentam, de modo geral, as menores probabilidades de sobrevivência ao longo do acompanhamento, ao passo que a categoria Carro fica na posição intermediária entre os demais grupos. Já os funcionários que vão a pé mantêm as maiores probabilidades.

Dado que as curvas apresentam poucos cruzamentos, considera-se que a suposição de proporcionalidade dos riscos foi atendida. Assim, com o objetivo de testar a igualdade entre as curvas, foi realizado o Teste de Logrank, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Não há diferença entre as curvas.} \\ H_1 : \text{Há diferença entre as curvas.} \end{cases}$$

A tabela a seguir exhibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 5: Resultado do Teste de Logrank para verificação da igualdade entre as curvas

Variável	p-valor	Decisão
Transporte	0,003	Rejeita a hipótese nula

O resultado apresentado na Tabela 5 indica que, ao nível de significância de 5%, há evidências estatísticas suficientes para rejeitar a hipótese nula de igualdade entre as curvas de sobrevivência.

4.7 Salário Cinza

Esta seção procura investigar o comportamento da variável Salário Cinza, que indica se o funcionário recebia parte de sua remuneração de forma não declarada oficialmente às autoridades fiscais. Para isso, foi construído um gráfico com as curvas de sobrevivência dos grupos da variável, exibido a seguir:




Figura 9: Curva de sobrevivência da variável Salário Cinza

A Figura 9 revela que a probabilidade de sobrevivência para indivíduos que recebem salário cinza cai de forma rápida, sobretudo nos primeiros 40 meses. Além disso, a estimativa de sobrevivência atinge zero pouco depois dos 125 meses. Por outro lado, a curva que representa os funcionários que não recebem salário cinza decresce de modo mais suave e constante.

Dado que as curvas não apresentam cruzamentos, considera-se que a suposição de proporcionalidade dos riscos foi atendida. Assim, com o objetivo de testar a igualdade entre as curvas, foi realizado o Teste de Logrank, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Não há diferença entre as curvas.} \\ H_1 : \text{Há diferença entre as curvas.} \end{cases}$$

A tabela a seguir exhibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 6: Resultado do Teste de Logrank para verificação da igualdade entre as curvas

Variável	p-valor	Decisão
Salário Cinza	< 0,001	Rejeita a hipótese nula

O resultado apresentado na Tabela 6 indica que, ao nível de significância de 5%, há evidências estatísticas suficientes para rejeitar a hipótese nula de igualdade entre as curvas de sobrevivência.

4.8 Profissão

Esta seção tem como objetivo estudar o comportamento da variável Profissão, que representa a profissão exercida pelo funcionário.

A variável possui 15 categorias: contabilidade, negócios, comercial, consultoria, engenharia, finanças, RH (recursos humanos), TI (tecnologia da informação), direito, gestão, marketing, RP (relações públicas), vendas, ensino e outros. O gráfico da curva de sobrevivência pelas categorias da variável é exibido a seguir:




Figura 10: Curva de sobrevivência da variável Profissão

A partir da Figura 10, verifica-se elevada heterogeneidade entre as curvas, indicando que o tempo de permanência dos funcionários varia entre as diferentes profissões.

Algumas categorias, como Contabilidade, Direito e TI, apresentam probabilidades de sobrevivência relativamente mais elevadas durante parte do acompanhamento, enquanto Engenharia, Ensino, Gestão e Marketing exibem reduções mais acentuadas nos

primeiros meses. Entretanto, essas diferenças não permanecem constantes ao longo do tempo, uma vez que as curvas se cruzam repetidamente. Esses cruzamento indicam violação da suposição de proporcionalidade dos riscos.

A fim de testar a igualdade das curvas e dado que os riscos não são proporcionais, foi realizado o Teste de Wilcoxon, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Não há diferença entre as curvas.} \\ H_1 : \text{Há diferença entre as curvas.} \end{cases}$$

A tabela a seguir exibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 7: Resultado do Teste de Wilcoxon para verificação da igualdade entre as curvas

Variável	p-valor	Decisão
Profissão	0,003	Rejeita a hipótese nula

O resultado apresentado na Tabela 7 indica que, ao nível de significância de 5%, existem evidências estatísticas suficientes para rejeitar a hipótese nula de igualdade entre as curvas de sobrevivência.

4.9 Canal de Recrutamento

Esta seção busca analisar o comportamento da variável Canal de Recrutamento, que indica por qual meio o funcionário chegou à empresa.

A variável apresenta oito categorias: contato direto com a empresa, recrutamento via portal de empregos, networking/conhecidos, agência de recrutamento, recomendação de terceiros, indicação externa, indicação interna e candidatura realizada por meio de portal de empregos. O gráfico da curva de sobrevivência pelas categorias da variável é mostrado a seguir:




Figura 11: Curva de sobrevivência da variável Canal de Recrutamento

A Figura 11 mostra que as probabilidades de sobrevivência são semelhantes durante os primeiros meses de acompanhamento, embora as categorias passem a apresentar comportamentos distintos à medida que o tempo avança.

Os funcionários recrutados por meio de contato direto e indicação externa apresentam, de modo geral, as maiores probabilidades de sobrevivência durante grande parte do período observado, indicando maior permanência no emprego. Em contrapartida, os indivíduos recrutados via portal exibem uma redução mais acentuada na probabilidade de sobrevivência desde os primeiros meses de acompanhamento, mantendo-se abaixo das demais categorias ao longo de boa parte do estudo.

As categorias networking/conhecidos, indicação interna, agência de recrutamento, recomendação de terceiros e candidatura via portal apresentam trajetórias intermediárias, com frequentes aproximações e cruzamentos entre as curvas. Esse comportamento sugere violação da suposição de riscos proporcionais.

A fim de testar a igualdade das curvas e dado que os riscos não são proporcionais, foi realizado o Teste de Wilcoxon, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Não há diferença entre as curvas.} \\ H_1 : \text{Há diferença entre as curvas.} \end{cases}$$

A tabela a seguir exibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 8: Resultado do Teste de Wilcoxon para verificação da igualdade entre as curvas

Variável	p-valor	Decisão
Profissão	$< 0,001$	Rejeita a hipótese nula

O resultado apresentado na Tabela 8 indica que, ao nível de significância de 5%, existem evidências estatísticas suficientes para rejeitar a hipótese nula de igualdade entre as curvas de sobrevivência.

4.10 Idade

Esta seção tem como objetivo analisar a variável Idade, que indica a idade do funcionário. Para isso, foram construídos um gráfico boxplot com a distribuição das idades segundo a ocorrência do evento e uma tabela de medidas resumo, apresentados a seguir:




Figura 12: Boxplot da variável Idade

Tabela 9: Medidas resumo da variável Idade

Estatística	Censura	Falha
Média	31,40	30,70
Desvio-padrão	6,81	7,16
Mínimo	19,00	18,00
1º Quartil	26,00	25,00
Mediana	30,70	30,00
3º Quartil	35,00	36,00
Máximo	56,00	58,00

A partir da Figura 12 e da Tabela 9 observa-se que os grupos de censura e falha apresentam distribuições bastante semelhantes. A idade média dos indivíduos censurados foi de 31,40 anos, enquanto para aqueles que apresentaram falha a média foi de 30,70 anos. As medianas também foram próximas, correspondendo a 30,70 e 30,00 anos, respectivamente. Em relação ao desvio-padrão, foi observada uma dispersão ligeiramente maior dos dados para o grupo de falha.

Os intervalos interquartílicos indicam que 50% das observações do grupo censurado encontram-se entre 26 e 35 anos, ao passo que, no grupo de falha, situam-se entre 25 e 36 anos, evidenciando dispersão semelhante entre os grupos. Os valores mínimos e máximos variaram de 19 a 56 anos entre os censurados e de 18 a 58 anos entre os indivíduos que apresentaram o evento.

Adicionalmente, observa-se a presença de valores discrepantes em ambos os grupos, concentrados nas idades mais elevadas. De modo geral, não são observadas diferenças substanciais na distribuição etária entre funcionários censurados e aqueles que apresentaram falha.

4.11 Ansiedade

Esta seção busca analisar o comportamento da variável Ansiedade, que representa um indicador que mede o nível de ansiedade do funcionário. Para isso, foram construídos um gráfico boxplot com a distribuição dos escores segundo a ocorrência do evento e uma tabela de medidas resumo, exibidos a seguir:




Figura 13: Boxplot da variável Ansiedade

Tabela 10: Medidas resumo da variável Ansiedade

Estatística	Censura	Falha
Média	5,77	5,56
Desvio-padrão	1,68	1,73
Mínimo	1,70	1,70
1º Quartil	4,80	4,00
Mediana	5,60	5,60
3º Quartil	7,10	6,30
Máximo	10,00	10,00

A Figura 13 e Tabela 10 mostram que os grupos de censura e falha apresentam distribuições bastante semelhantes, embora os indivíduos censurados apresentem, em média, níveis ligeiramente mais elevados de ansiedade.

A média do escore de ansiedade foi de 5,77 pontos entre os indivíduos censurados e de 5,56 pontos entre aqueles que apresentaram falha. As medianas foram idênticas nos dois grupos, correspondendo a 5,60 pontos, e os desvios-padrões também estão muito próximos, com 1,68 para o grupo de censura e 1,73 para o grupo de falha.

Com relação à dispersão, verifica-se que 50% dos indivíduos censurados possuem escores de ansiedade entre 4,80 e 7,10 pontos, enquanto, entre os indivíduos que apresen-

taram falha, os escores estão entre 4,00 e 6,30 pontos. Dessa forma, é possível notar que a amplitude interquartílica é igual para os dois grupos, embora situe-se em valores mais elevados para o grupo censurado.

Os valores mínimos e máximos foram iguais nos dois grupos, variando entre 1,70 e 10,00 pontos. O boxplot evidencia apenas um outlier superior no grupo de falha, correspondente a um indivíduo com escore de ansiedade elevado em relação aos demais participantes desse grupo.

De modo geral, os resultados indicam que os níveis de ansiedade são semelhantes entre os grupos de censura e falha, não sendo observadas diferenças expressivas na distribuição dessa variável entre os indivíduos que experimentaram ou não o evento.

4.12 Extroversão

Esta seção procura examinar o comportamento da variável Extroversão, que representa um indicador do quão extrovertido é o funcionário. Para isso, foram construídos um gráfico boxplot com a distribuição das dos escores segundo a ocorrência do evento e uma tabela de medidas resumo, mostrados a seguir:




Figura 14: Boxplot da variável Extroversão

Tabela 11: Medidas resumo da variável Extroversão

Estatística	Censura	Falha
Média	5,56	5,62
Desvio-padrão	1,85	1,86
Mínimo	1,00	1,00
1º Quartil	4,60	4,20
Mediana	5,40	5,40
3º Quartil	7,00	7,00
Máximo	10,00	10,00

A partir da Figura 14 e da Tabela 11, nota-se que os grupos de censura e falha apresentam distribuições muito semelhantes. A média dos indivíduos censurados foi de 5,56, enquanto para aqueles que apresentaram falha a média foi de 5,62 anos. As medianas foram idênticas, com valor igual a 5,40 para os dois grupos. Os desvios-padrões obtidos também são praticamente iguais, sendo 1,85 para o grupo de censura e 1,86 para o grupo de falha.

Com relação à dispersão, verifica-se que 50% dos indivíduos censurados possuem escores de extroversão entre 4,60 e 7,00 pontos, enquanto, entre os indivíduos que apresentaram falha, os escores situam-se entre 4,20 e 7,00 pontos. Dessa forma, nota-se que a amplitude interquartílica é ligeiramente maior entre os indivíduos que falharam.

Os valores mínimos e máximos foram iguais nos dois grupos, variando entre 1,00 e 10,00 pontos. O boxplot não evidencia a presença de valores discrepantes, o que sugere uma distribuição relativamente homogênea da variável.

De modo geral, os resultados indicam que os níveis de extroversão são semelhantes entre os grupos de censura e falha, não sendo observadas diferenças expressivas na distribuição dessa variável entre os indivíduos que experimentaram ou não o evento.

4.13 Independência

Esta seção tem como objetivo analisar o comportamento da variável Independência, que representa um indicador do nível de autonomia do funcionário. Para isso, foram construídos um gráfico boxplot com a distribuição dos escores segundo a ocorrência do evento e uma tabela de medidas resumo, exibidos a seguir:




Figura 15: Boxplot da variável Independência

Tabela 12: Medidas resumo da variável Independência

Estatística	Censura	Falha
Média	5,39	5,57
Desvio-padrão	1,72	1,68
Mínimo	1,00	1,00
1º Quartil	4,10	4,10
Mediana	5,50	5,50
3º Quartil	6,90	6,90
Máximo	9,80	10,00

A partir da Figura 15 e da Tabela 12 observa-se que os grupos de censura e falha apresentam distribuições bastante semelhantes. O escore médio de independência dos indivíduos censurados foi de 5,39, enquanto para aqueles que apresentaram falha a média foi de 5,57. Em relação ao desvio-padrão, os resultados também foram muito próximos, sendo 1,72 para os indivíduos censurados e 1,68 para os que falharam.

O intervalo interquartil foi de 2,80 para os dois grupos, sendo o primeiro e terceiro quartil idênticos nas duas distribuições. Os valores de mínimo e mediana também foram iguais, sendo 1,00 e 5,50 respectivamente. O máximo foi de 9,80 para as observações censuradas e 10,00 para as observações de falha.

Portanto, os resultados indicam que os níveis de independência são semelhantes entre os grupos de censura e falha, não sendo observadas diferenças expressivas na distribuição dessa variável entre os indivíduos que experimentaram ou não o evento.

4.14 Inovação

Esta seção procura investigar o comportamento da variável Inovação, que representa um indicador do nível de abertura do funcionário à inovação e à novas experiências. Para isso, foram construídos um gráfico boxplot com a distribuição dos escores segundo a ocorrência do evento e uma tabela de medidas resumo, exibidos a seguir:




Figura 16: Boxplot da variável Inovação

Tabela 13: Medidas resumo da variável Inovação

Estatística	Censura	Falha
Média	5,87	5,89
Desvio-padrão	1,91	1,90
Mínimo	1,00	1,00
1º Quartil	4,40	4,40
Mediana	6,00	6,00
3º Quartil	7,50	7,50
Máximo	10,00	10,00

A Figura 16 e da Tabela 13 indicam que os grupos de censura e falha apresentam distribuições praticamente idênticas. O escore médio de inovação dos indivíduos censurados foi de 5,87, enquanto para aqueles que apresentaram falha a média foi de 5,89. Em relação ao desvio-padrão, os resultados também foram muito próximos, sendo 1,91 para os indivíduos censurados e 1,90 para os que falharam.

O intervalo interquartil foi de 3,10 para os dois grupos, sendo o primeiro e terceiro quartil idênticos nas duas distribuições. Os valores de mínimo, mediana e máximo também foram iguais, sendo 1,00, 6,00 e 10,00, respectivamente.

Portanto, os resultados indicam que os níveis de inovação são semelhantes entre os grupos de censura e falha, não sendo observadas diferenças expressivas na distribuição dessa variável entre os indivíduos que experimentaram ou não o evento.

4.15 Autocontrole

Esta seção tem como objetivo estudar o comportamento da variável Autocontrole, que representa um indicador do nível de autocontrole do funcionário. Para isso, foram construídos um gráfico boxplot com a distribuição dos escores segundo a ocorrência do evento e uma tabela de medidas resumo, exibidos a seguir:




Figura 17: Boxplot da variável Autocontrole

Tabela 14: Medidas resumo da variável Autocontrole

Estatística	Censura	Falha
Média	5,68	5,52
Desvio-padrão	2,02	1,94
Mínimo	1,00	1,00
1º Quartil	4,10	4,10
Mediana	5,70	5,70
3º Quartil	7,70	7,20
Máximo	10,00	10,00

A Figura 17 e Tabela 14 mostram que os grupos de censura e falha apresentam distribuições bastante semelhantes, embora os indivíduos censurados apresentem, em média, níveis ligeiramente mais elevados de autocontrole.

A média do escore de autocontrole foi de 5,68 pontos entre os indivíduos censurados e de 5,52 pontos entre aqueles que apresentaram falha. As medianas foram idênticas nos dois grupos, correspondendo a 5,70 pontos, e os desvios-padrões também estão muito próximos, com 2,02 para o grupo de censura e 1,94 para o grupo de falha.

Com relação à dispersão, verifica-se que 50% dos indivíduos censurados possuem escores de autocontrole entre 4,10 e 7,70 pontos, enquanto, entre os indivíduos que apresentaram falha, os escores estão entre 4,10 e 7,20 pontos. Dessa forma, é possível notar que a amplitude interquartílica é levemente maior para o grupo de censura. Os valores mínimos e máximos foram iguais nos dois grupos, variando entre 1,00 e 10,00 pontos.

De modo geral, os resultados indicam que os níveis de autocontrole são semelhantes entre os grupos de censura e falha, não sendo observadas diferenças expressivas na distribuição dessa variável entre os indivíduos que experimentaram ou não o evento.

4.16 Correlação

Esta seção tem como objetivo compreender a relação das variáveis entre si a fim de identificar uma possível multicolinearidade. Para isso, foi calculado o coeficiente de correlação Spearman para todas as variáveis quantitativas. Já para as variáveis categóricas, a associação foi calculada com base na medida V de Cramér.

4.16.1 Correlação entre variáveis quantitativas

Para facilitar a visualização das correlações entre as variáveis quantitativas, foi construído um mapa de calor, apresentado a seguir. As cores variam do azul ao vermelho, representando correlações negativas e positivas, respectivamente, enquanto a intensidade

do tom indica a força da associação.




Figura 18: Mapa de calor da correlação entre as variáveis quantitativas

O gráfico da Figura 18 revela que a maioria das variáveis possuem correlação baixa entre si. No entanto, destaca-se correlação negativa moderada entre os pares Autocontrole e Extroversão, Autocontrole e Inovação e Ansiedade e Independência, com correlações de -0,53, -0,57 e -0,43, respectivamente. Tais valores não representam indícios graves de multicolinearidade, mas merecem atenção.

4.16.2 Correlação entre variáveis categóricas

Para avaliar a associação entre as variáveis categóricas, foi construído um mapa de calor com os valores da medida V de Cramér, apresentado a seguir. As cores variam do azul ao vermelho, representando a ausência de associação ou associação perfeita, respectivamente.




Figura 19: Mapa de calor da associação entre as variáveis categóricas

Com base na Figura 19 observa-se que a maioria das variáveis possuem associação baixa entre si. No entanto, destaca-se associação moderada entre os pares Profissão e Gênero e Profissão e Gênero do Supervisor, com valores de 0,50 e 0,34, respectivamente. Tais valores não representam indícios graves de multicolinearidade, mas merecem atenção.

5 Ajuste de distribuições

Nesta seção são apresentados os ajustes de modelos paramétricos para os tempos de sobrevivência, com o objetivo de identificar a distribuição que melhor descreve o comportamento dos dados observados. A utilização de modelos paramétricos permite representar a distribuição dos tempos até a ocorrência do evento de interesse por meio de uma função probabilística específica.

Foram consideradas oito distribuições: exponencial, Weibull, log-normal, log-logística e suas respectivas formas de locação-escala. O desempenho de cada modelo foi avaliado por meio do método gráfico e da medida de ajuste Critério de Informação Akaike (AIC). A partir dessa análise, buscou-se identificar quais distribuições fornecem representações mais adequadas dos dados.

Os gráficos e as tabelas construídos para comparação do ajuste das distribuições em relação à curva estimada de Kaplan-Meier são apresentados a seguir:




Figura 20: Curvas de sobrevivência exponencial, Weibull, log-normal e log-logística

A partir da Figura 20, observa-se que todas as distribuições reproduzem satisfatoriamente o comportamento dos dados ao longo da maior parte do período de acompanhamento. Entretanto, as distribuições log-normal e log-logística apresenta maior afastamento da curva empírica, principalmente nos tempos finais. As distribuições Weibull e exponencial mostraram maior proximidade com o estimador de Kaplan-Meier em praticamente todo o intervalo observado.

Tabela 15: Resultados do AIC

Distribuição	AIC
Log-logística	6032,22
Weibull	6032,55
Log-normal	6033,23
Exponencial	6034,61

A Tabela 15 mostra que todos os modelos resultaram em valores de AIC semelhantes. No entanto, a distribuição log-logística teve melhor desempenho em relação às demais. Por outro lado, a distribuição exponencial apresentou o menor AIC.




Figura 21: Curvas de sobrevivência valor extremo padrão, valor extremo, normal e logística

Com base na Figura 21, observa-se novamente que todas as distribuições apresentaram um ajuste relativamente dequado em relação à curva de sobrevivência estimada. É possível perceber que as distribuições normal e logística ficam mais próximas da curva estimada, embora produzam uma leve superestimção nos tempos finais. A distribuição valor extremo padrão tem o pior ajuste, afastando-se da curva empírica principalmente na parte inicial. Por fim, a distribuição valor extremo demonstrou um ajuste intermediário.

Tabela 16: Resultados do AIC

Distribuição	AIC
Logística	2503,83
Valor extremo	2504,17
Valor extremo padrão	2504,17
Normal	2504,85

A Tabela 16 revela que todos os modelos resultaram em valores de AIC semelhantes. No entanto, a distribuição logística teve melhor desempenho em relação às demais. Por outro lado, a distribuição normal apresentou o menor AIC.

6 Seleção de covariáveis

A etapa de seleção de covariáveis é fundamental para a construção de um modelo de regressão robusto, parcimonioso e estatisticamente consistente. Dado que as medidas de ajuste não indicaram um único modelo com melhor ajuste, foi realizada a seleção de covariáveis para todas as distribuições.

Três estratégias foram aplicadas: passo atrás, iniciando com o modelo contendo todas as covariáveis; passo à frente e passo a passo. Para todos os procedimentos, foi considerado o AIC como critério de seleção.

Os métodos resultaram em apenas um modelo para cada distribuição, com exceção da distribuição logística, que obteve dois modelos. As covariáveis selecionadas são apresentadas a seguir:

Tabela 17: Modelos sem locação-escala selecionados

Número	Distribuição	Covariáveis	AIC
1	<i>Log-normal</i>	<i>Idade, Indústria, Canal de Recrutamento, Mentoria, Salário Cinza, Autocontrole, Ansiedade</i>	5964,97
2	<i>Weibull</i>	<i>Idade, Indústria, Canal de Recrutamento, Salário Cinza, Autocontrole, Ansiedade, Profissão, Transporte</i>	5944,43
3	<i>Exponencial</i>	<i>Idade, Indústria, Canal de Recrutamento, Salário Cinza, Autocontrole, Ansiedade, Transporte</i>	5965,93
4	<i>Log-logística</i>	<i>Idade, Indústria, Canal de Recrutamento, Salário Cinza, Autocontrole, Ansiedade, Profissão</i>	5954,92

Tabela 18: Modelos com locação-escala selecionados

Número	Distribuição	Covariáveis	AIC
5	<i>Valor extremo padrão</i>	<i>Idade, Indústria, Canal de Recrutamento, Salário Cinza, Autocontrole, Ansiedade, Profissão, Transporte</i>	2416,05
6	<i>Valor extremo</i>	<i>Idade, Indústria, Canal de Recrutamento, Salário Cinza, Autocontrole, Ansiedade, Profissão, Transporte</i>	2416,05
7	<i>Normal</i>	<i>Idade, Indústria, Canal de Recrutamento, Mentoria, Salário Cinza, Autocontrole, Ansiedade</i>	2436,59
8	<i>Logística 1</i>	<i>Idade, Indústria, Canal de Recrutamento, Salário Cinza, Autocontrole, Ansiedade, Profissão, Transporte</i>	2427,28
9	<i>Logística 2</i>	<i>Idade, Indústria, Canal de Recrutamento, Mentoria, Salário Cinza, Autocontrole, Ansiedade, Profissão, Transporte</i>	2427,46

As Tabelas 17 e 18 mostram que, com base no AIC, o ajuste com melhor desempenho dentre os modelos sem locação-escala foi o modelo da Weibull, de número 2. Para o grupo dos modelos com locação-escala, os melhores valores foram observados para os ajustes 5 e 6.

7 Análise de diagnóstico

A análise de diagnóstico busca avaliar a qualidade do ajuste do modelo. Essa etapa permite verificar se o modelo descreve adequadamente os dados observados, detectar observações atípicas, padrões sistemáticos não explicados e indícios de inadequação da distribuição paramétrica adotada.

7.1 Resíduo de Cox-Snell

Os resíduos de Cox-Snell auxiliam a examinar o ajuste global do modelo. São apresentados a seguir os gráficos da comparação entre a função de sobrevivência empírica dos resíduos e a sobrevivência teórica esperada para cada um dos modelos selecionados




Figura 22: Análise dos resíduos de Cox-Snell do modelo Log-Normal




Figura 23: Análise dos resíduos de Cox-Snell do modelo Weibull




Figura 24: Análise dos resíduos de Cox-Snell do modelo Log-Logística




Figura 25: Análise dos resíduos de Cox-Snell do modelo Exponencial




Figura 26: Análise dos resíduos de Cox-Snell do modelo Valor Extremo Padrão




Figura 27: Análise dos resíduos de Cox-Snell do modelo Valor Extremo




Figura 28: Análise dos resíduos de Cox-Snell do modelo Normal




Figura 29: Análise dos resíduos de Cox-Snell do modelo Logística 1




Figura 30: Análise dos resíduos de Cox-Snell do modelo Logística 2

As Figuras 22 a 30 apresentam a análise dos resíduos de Cox-Snell para os modelos ajustados. Observa-se que o modelo Weibull (Figura 23) se assemelha mais à distribuição teórica, indicando que os resíduos se aproximam do comportamento esperado. Nos demais modelos, verificam-se desvios mais acentuados em relação à curva exponencial,

especialmente nos tempos finais de acompanhamento, e, em alguns casos, também nos tempos iniciais, sugerindo pior adequação aos dados.

Assim, entre os modelos avaliados, o modelo Weibull foi o que apresentou o melhor ajuste segundo o diagnóstico baseado nos resíduos de Cox-Snell.

8 Interpretação do modelo selecionado

A partir das análises realizadas, o modelo de regressão com distribuição Weibull foi selecionado para representar o tempo de permanência dos funcionários na empresa. Esse modelo apresentou o menor AIC entre os modelos ajustados diretamente ao tempo e o melhor comportamento na análise dos resíduos de Cox-Snell.

O modelo selecionado contém as covariáveis idade, indústria, profissão, canal de recrutamento, salário cinza, transporte, autocontrole e ansiedade. Na forma de um modelo de tempo de falha acelerado, ele pode ser representado por

$$\begin{aligned} T_i = & \beta_0 + \beta_1 \text{Idade}_i + \beta_2^T \text{Indústria}_i + \beta_3^T \text{Profissão}_i \\ & + \beta_4^T \text{Canal}_i + \beta_5 \text{SalárioCinza}_i + \beta_6^T \text{Transporte}_i \\ & + \beta_7 \text{Autocontrole}_i + \beta_8 \text{Ansiedade}_i \end{aligned}$$

em que T_i representa o tempo de permanência do funcionário i .

As variáveis indústria, profissão, canal de recrutamento e transporte são categóricas e foram incluídas por meio de variáveis indicadoras. As categorias de referência foram Agricultura para indústria, Contabilidade para profissão, Contato direto para canal de recrutamento e Ônibus para transporte.

A Tabela 19 apresenta os coeficientes que foram estatisticamente significativos ao nível de 5%. A tabela completa com todas as estimativas do modelo é apresentada no Apêndice A.

Tabela 19: Coeficientes significativos do modelo Weibull selecionado

Termo	Estimativa	Erro-padrão	Estatística Z	p-valor	Fator de aceleração
Idade	-0,0185	0,0053	-3,4771	0,001	0,98
Indústria: TI	1,1013	0,3231	3,4082	0,001	3,01
Indústria: Manufatura	0,7988	0,3076	2,5972	0,009	2,22
Indústria: Farmácia	0,8135	0,3850	2,1132	0,035	2,26
Indústria: Energia	0,8969	0,3616	2,4803	0,013	2,45
Indústria: Imobiliária	1,5674	0,4861	3,2244	0,001	4,79
Indústria: Varejo	0,9492	0,2958	3,2088	0,001	2,58
Indústria: Estatal	0,6716	0,3367	1,9943	0,046	1,96
Indústria: Telecomunicação	1,0985	0,3660	3,0009	0,003	3,00
Indústria: Transporte	0,7586	0,3547	2,1389	0,032	2,14
Profissão: Comercial	-0,8262	0,4187	-1,9732	0,048	0,44
Profissão: Gestão	-1,1165	0,4171	-2,6769	0,007	0,33
Canal: Recrutamento via portal	-0,7182	0,2585	-2,7784	0,005	0,49
Salário branco	0,4208	0,1109	3,7936	< 0,001	1,52
Transporte: A pé	0,2902	0,1445	2,0084	0,045	1,34
Autocontrole	0,0562	0,0188	2,9847	0,003	1,06
Ansiedade	0,0481	0,0218	2,2107	0,027	1,05

Nota: As categorias de referência são Agricultura, Contabilidade, Contato direto, Salário cinza e Ônibus. O fator de aceleração corresponde a $\exp(\hat{\beta})$.

Em modelos de tempo de falha acelerado, a exponencial do coeficiente estimado,

$$\exp(\hat{\beta}_j),$$

representa o fator pelo qual o tempo de permanência é multiplicado. Sua interpretação pode ser resumida por

$$\begin{cases} \exp(\hat{\beta}_j) > 1, & \text{o aumento da covariável ou a categoria está associado a maior tempo;} \\ \exp(\hat{\beta}_j) = 1, & \text{não há alteração no tempo associada à covariável;} \\ \exp(\hat{\beta}_j) < 1, & \text{o aumento da covariável ou a categoria está associado a menor tempo.} \end{cases}$$

As interpretações das covariáveis são realizadas mantendo-se constantes as demais variáveis presentes no modelo.

8.1 Idade

A idade apresentou coeficiente negativo e estatisticamente significativo. Para cada aumento de um ano na idade do funcionário, o tempo de permanência estimado é multiplicado por 0,98, mantendo-se constantes as demais covariáveis.

Esse resultado corresponde a uma redução aproximada de 2% no tempo de permanência para cada ano adicional de idade.

8.2 Indústria

A variável Indústria foi incluída no modelo por meio de variáveis indicadoras, utilizando o setor de Agricultura como categoria de referência.

Entre as categorias que apresentaram significância estatística, todos os coeficientes foram positivos. Portanto, os funcionários pertencentes a esses setores apresentaram tempos de permanência estimados superiores aos dos funcionários do setor de Agricultura, mantendo-se constantes as demais covariáveis.

O maior efeito foi observado no setor Imobiliário. Para os funcionários desse setor, o tempo de permanência foi multiplicado por 4,79, correspondendo a um aumento aproximado de 379% em relação ao setor de Agricultura.

Os setores de TI e Telecomunicação apresentaram fatores de aceleração próximos de 3,00. Dessa forma, os tempos de permanência estimados nesses setores foram aproximadamente três vezes os observados no setor de Agricultura.

Para os demais setores significativos, foram observados os seguintes resultados:

Setor	Fator de aceleração	Aumento aproximado
Manufatura	2,22	122%
Farmácia	2,26	126%
Energia	2,45	145%
Varejo	2,58	158%
Estatal	1,96	96%
Transporte	2,14	114%

Esses resultados devem ser interpretados somente em relação ao setor de Agricultura. Para as categorias que não apresentaram significância estatística ao nível de 5%, não foram encontradas evidências suficientes de diferença em relação à categoria de referência.

8.3 Profissão

A variável Profissão foi incluída no modelo utilizando Contabilidade como categoria de referência. Apenas as categorias Comercial e Gestão apresentaram efeitos estatisticamente significativos ao nível de 5%.

Para os profissionais da área Comercial, o tempo de permanência foi multiplicado por 0,44. Isso corresponde a uma redução aproximada de 56% em relação aos funcionários da área de Contabilidade.

Para os profissionais da área de Gestão, o tempo de permanência foi multiplicado por 0,33, indicando uma redução aproximada de 67% em relação à categoria de referência.

Portanto, mantendo-se constantes as demais variáveis, os funcionários das áreas Comercial e Gestão apresentaram tempos de permanência estimados inferiores aos dos funcionários da área de Contabilidade.

8.4 Canal de recrutamento

A variável Canal de Recrutamento foi incluída no modelo utilizando Contato direto como categoria de referência.

Entre as categorias avaliadas, apenas Recrutamento via portal apresentou efeito estatisticamente significativo ao nível de 5%. Para os funcionários recrutados por esse canal, o tempo de permanência foi multiplicado por 0,49.

Esse resultado corresponde a uma redução aproximada de 51% no tempo de permanência em relação aos funcionários recrutados por contato direto, mantendo-se constantes as demais covariáveis.

8.5 Salário cinza

A categoria de referência dessa variável corresponde aos funcionários que recebiam salário cinza, isto é, parte da remuneração não era declarada oficialmente.

O coeficiente estimado para o grupo de funcionários que não recebia salário cinza foi positivo e estatisticamente significativo. O tempo de permanência dos funcionários nessa categoria foi multiplicado por 1,52, representando um aumento aproximado de 52% em relação aos funcionários que recebiam salário cinza.

8.6 Transporte

A variável Transporte foi incluída utilizando Ônibus como categoria de referência. Entre as modalidades avaliadas, apenas o deslocamento a pé apresentou efeito estatisticamente significativo ao nível de 5%.

Para os funcionários que se deslocavam a pé, o tempo de permanência foi multiplicado por 1,34. Esse resultado representa um aumento aproximado de 34% em relação aos funcionários que utilizavam ônibus.

8.7 Autocontrole e ansiedade

As variáveis Autocontrole e Ansiedade foram incluídas como covariáveis quantitativas.

Para cada aumento de uma unidade no escore de Autocontrole, o tempo de permanência foi multiplicado por 1,06, o que corresponde a um aumento aproximado de 6%.

Para cada aumento de uma unidade no escore de Ansiedade, o tempo de permanência foi multiplicado por 1,05, representando um aumento aproximado de 5%.

Entretanto, a interpretação substantiva desses resultados exige cautela. A documentação da base de dados não apresenta informações suficientes sobre a construção e a direção dessas escalas. Assim, não é possível garantir que valores mais altos representem necessariamente maior ansiedade ou maior autocontrole.

Os resultados permitem afirmar apenas que aumentos nos escores registrados estão associados a maiores tempos de permanência. A interpretação desses aumentos como níveis mais altos ou mais baixos das características avaliadas depende da forma como as escalas foram construídas.

9 Conclusão

Os resultados indicaram que o modelo Weibull foi o mais adequado entre os modelos finais ajustados diretamente ao tempo, apresentando o menor AIC nesse grupo e comportamento satisfatório na análise dos resíduos de Cox-Snell. O modelo final foi composto pelas variáveis idade, indústria, profissão, canal de recrutamento, tipo de remuneração, transporte, autocontrole e ansiedade.

As estimativas mostraram que o tempo de permanência dos funcionários está associado tanto a características individuais quanto a fatores profissionais e organizacionais.

O aumento da idade esteve associado a menores tempos de permanência. Também foram observados tempos inferiores para profissionais das áreas Comercial e Gestão e para funcionários recrutados por portal, considerando as respectivas categorias de referência.

Em sentido contrário, algumas categorias da variável Indústria apresentaram tempos de permanência superiores aos observados no setor de Agricultura, com destaque para o setor Imobiliário. O recebimento de salário integralmente formalizado e o deslocamento a pé também estiveram associados a maiores tempos de permanência.

Os escores de autocontrole e ansiedade apresentaram associações positivas com o tempo observado. Entretanto, a ausência de informações detalhadas sobre a construção e a direção dessas escalas limita a interpretação substantiva desses resultados. Assim, é possível afirmar que maiores valores registrados nos escores estiveram associados a maior permanência, mas não necessariamente que maiores níveis das características avaliadas produzam esse efeito.

Os resultados devem ser entendidos como associações estatísticas, e não como relações de causa e efeito. Além disso, a ausência de informações completas sobre o processo de coleta, a população representada e a construção de algumas variáveis restringe a generalização das conclusões.

De modo geral, o modelo permitiu identificar perfis e características associados a diferentes tempos de permanência na empresa. Esses resultados podem auxiliar na formulação de hipóteses sobre a rotatividade de funcionários e orientar análises futuras com bases de dados que apresentem informações mais detalhadas sobre o contexto organizacional e o acompanhamento dos trabalhadores.

A Estimativas completas do modelo Weibull

Tabela 20: Estimativas completas do modelo de regressão Weibull

Variável	Estimativa	Erro-padrão	Estatística Z	p-valor
Intercepto	3,69530	0,58531	6,31	< 0,001
Idade	-0,01854	0,00533	-3,48	0,001
Indústria: Bancos	0,30751	0,30415	1,01	0,312
Indústria: Construção	0,26593	0,32624	0,82	0,415
Indústria: Consultoria	0,43567	0,31002	1,41	0,160
Indústria: Outros	0,59146	0,30943	1,91	0,056
Indústria: HoReCa	0,73601	0,45308	1,62	0,104
Indústria: Tecnologia da Informação	1,10126	0,32312	3,41	0,001
Indústria: Manufatura	0,79883	0,30757	2,60	0,009
Indústria: Mineração	0,63600	0,37207	1,71	0,087
Indústria: Farmácia	0,81352	0,38496	2,11	0,035
Indústria: Energia	0,89690	0,36161	2,48	0,013
Indústria: Imobiliária	1,56745	0,48612	3,22	0,001
Indústria: Varejo	0,94919	0,29581	3,21	0,001
Indústria: Estatal	0,67156	0,33674	1,99	0,046
Indústria: Telecomunicação	1,09847	0,36605	3,00	0,003
Indústria: Transporte	0,75862	0,35467	2,14	0,032
Profissão: Desenvolvimento de Negócios	-0,50213	0,42064	-1,19	0,233
Profissão: Comercial	-0,82616	0,41869	-1,97	0,048
Profissão: Consultoria	-0,50601	0,42676	-1,19	0,236
Profissão: Engenharia	-0,84672	0,44316	-1,91	0,056
Profissão: Outros	-0,40826	0,40485	-1,01	0,313
Profissão: Finanças	-0,17684	0,43121	-0,41	0,682
Profissão: Recursos Humanos	-0,21914	0,35604	-0,62	0,538
Profissão: Tecnologia da Informação	-0,03976	0,39811	-0,10	0,920
Profissão: Direito	-0,33546	0,53828	-0,62	0,533
Profissão: Gestão	-1,11650	0,41709	-2,68	0,007
Profissão: Marketing	-0,64164	0,40099	-1,60	0,110
Profissão: Relações Públicas	-0,71016	0,53669	-1,32	0,186
Profissão: Vendas	-0,49775	0,38223	-1,30	0,193
Profissão: Ensino	-0,54066	0,47873	-1,13	0,259
Canal: Recrutamento via portal	-0,71817	0,25848	-2,78	0,005
Canal: Networking ou conhecidos	-0,02756	0,28014	-0,10	0,922

Continua na próxima página

Tabela 20 – continuação

Variável	Estimativa	Erro-padrão	Estatística Z	p -valor
Canal: Agência de recrutamento	-0,09381	0,29140	-0,32	0,748
Canal: Recomendação de terceiros	-0,37274	0,25591	-1,46	0,145
Canal: Indicação externa	0,08641	0,31364	0,28	0,783
Canal: Indicação interna	-0,23576	0,26974	-0,87	0,382
Canal: Candidatura via portal	-0,49757	0,25539	-1,95	0,051
Salário branco	0,42085	0,11094	3,79	< 0,001
Transporte: Carro	0,14437	0,08448	1,71	0,087
Transporte: A pé	0,29015	0,14447	2,01	0,045
Autocontrole	0,05624	0,01884	2,98	0,003
Ansiedade	0,04810	0,02176	2,21	0,027
log(escala)	-0,17099	0,03314	-5,16	< 0,001

Nota: As categorias de referência são Agricultura para Indústria, Contabilidade para Profissão, Contato direto para Canal de Recrutamento, Salário cinza para o tipo de remuneração e Ônibus para Transporte.

O parâmetro de escala estimado é

$$\hat{\sigma} = \exp(-0,17099) \approx 0,843.$$

Consequentemente, o parâmetro de forma da distribuição Weibull é

$$\hat{\gamma} = \frac{1}{\hat{\sigma}} \approx 1,186.$$

Referências

COLOSIMO, E. A.; GIOLO, S. R. *Análise de Sobrevivência Aplicada*. São Paulo: Edgard Blücher, 2006.

KLEIN, J. P.; MOESCHBERGER, M. L. *Survival Analysis: Techniques for Censored and Truncated Data*. 2. ed. New York: Springer, 2003.

LAWLESS, J. F. *Statistical Models and Methods for Lifetime Data*. 2. ed. Hoboken: Wiley, 2003.